


Nama: William Sebastian Liman

NIM: 2702210434



1. Bagian yang ditunjuk oleh x adalah raw audio data dimana raw audio data berupa Kumpulan banyak frame yang direpresentasikan dengan sebuah angka. Pada sebuah audio 16 kHz dengan durasi 1 detik jumlah framenya adalah 16.000. raw audio direpresentasikan dengan sebuah vector 1 dimensi dengan size dari vector tsb adalah jumlah framenya

2.

Bagian yang ditunjuk dengan Z adalah output dari model CNN Ketika kita memasukan raw audio data sebagai inputnya. Dalam model CNN terdapat beberapa filter (kernel) dengan size 3 dan stride 1. Sebuah kernel dengan size 3 memiliki arti bahwa terdapat 3 weight dalam kernel tsb misal $[0.7, 0.2, -0.1]$. Pada awalnya sebuah kernel memiliki angka yang random. Namun melalui back propagation weight dri kernel tersebut akan berubah. Stride 1 memiliki arti bahwa pergerseran kernel ke time step selanjutnya adalah 1 step. Output dari model CNN adalah Z dimana Z adalah feature representation dari raw audio tersebut. Dalam Wav2Vec 1.0 Z adalah feature representation yang continus dimana feature tersebut direpresentasikan dengan sebuah vector 2 dimensi. Kolom pada vector tersebut menandakan time step pada audio dan sedangkan baris pada vector tersebut menandakan feature yang diekstrak.

3.

Output dari CNN (z) akan menjadi input dari contextual network dan akan diubah menjadi C (contextualized feature representation). Target dari contextual network adalah untuk mempelajari long term temporal dependencies diantara feature pada sebuah speech. Contextual network akan mempelajari relasi antar feature melalui contrastive learning dimana model akan di train untuk membuat positive pair lebih dekat dengan yang lain dan membuat negative pair menjauhi yang lainnya. Contrastive learning akan meminimalisir jarak antara feature vector dengan positive pair sedangkan memaksimalkan jarak antara feature vector dengan negative pair

4. Pada tahap ini model sudah selesai di pre-training dan kita perlu melakukan fine-tuning pada model tersebut dengan memberikan dataset medium yang sudah dilabel dengan transkripnya. Model akan menggunakan algo seperti CTC untuk menghubungkan feature dan relasi antar feature dengan transkripsinya.

2.

Persamaan: Semua model Wav2Vec, Wav2Vec 2.0, XLSR, XLSR-53, dan X-LSR proses pre-trainingnya adalah Unsupervised dan inputnya adalah raw audio.

Model	Quantization	Learning Objective	Focus	Language-agnostic	Use of transformer
Wav2Vec	No	Context leaning by Constractive learning	Continues feature extraction from raw audio	No	No
Wav2Vec2.0	Yes	Context learning by masking some Q in the vector	Quantization of speech feature	Yes	Yes
XLSR	Yes	Context leaning by Constractive learning, and fine tune with CTC	Multilingual ASR and transfer learning between language	Yes	Yes
XLSR-53	Yes	Context leaning by Constractive learning, and fine tune with CTC	Multilingual ASR up to 53 language	Yes	Yes
X-LSR	Yes	Context leaning by	Cross-lingual ASR (learn to	Yes	Yes

		Constractive learning, and fine tune with CTC	transcript language it never trained on based on other language)		
--	--	---	--	--	--